

RetailBench ARR Revision 与 paper/latex 版本差异说明

RetailBench Revision Notes

2026-05-25

1 目的

本文档说明当前 `paper/latex_arr_revision` 版本相对于 `paper/latex` 版本的主要差异。比较范围以两个目录中当前的 LaTeX 源码、表格、图表和参考文献文件为准，不包含外部实验原始日志。

2 总体结论

`paper/latex_arr_revision` 已经从早期的 “simulator + method” 叙述转向 “benchmark + evaluation + diagnostic analysis” 叙述。新版主线更集中：它强调 RetailBench 是一个 data-grounded、long-horizon、partially observable retail operation benchmark，并围绕 environment construction、evaluation protocol、main results 和 four-stage diagnostic analysis 展开。旧版 `paper/latex` 保留了更多早期章节结构，例如 simulator execution logic、standalone results section、prompt/framework appendix，以及部分旧实验叙述。

3 结构差异

4 内容差异

1. **Benchmark positioning** 更明确。新版 introduction 和 related work 将 RetailBench 定位为 long-horizon retail operation benchmark，减少对短任务或通用 agent benchmark 的泛泛比较，并补充 LifelongAgentBench 和 TheAgentCompany 等 long-horizon/workplace agent benchmark。
2. **Environment construction** 更结构化。新版将环境描述拆为 benchmark、POMDP、data、modules 四个逻辑层次。正文只保留高层说明，详细 state space、action space、module definitions、day-level update equations 和 hand-crafted policy 放到 appendix。
3. **Figure 设计被重排**。新版将 retail simulator module figure 作为 Figure 1 放在第一页右栏顶部，并将 agent-simulator interaction framework 作为 Figure 2 双栏展示。旧版图表更接近初始 draw.io 版本，缺少 shelf assortment 和当前交互框架的统一表达。

维度	paper/latex	latex_arr_revision
正文组织	Introduction, Environment, Simulator Module Design, Experiment Settings, Results, Analysis, Related Work	Introduction, Environment Construction, Evaluation Protocol, Experiments, Analysis, Related Work
环境描述	更偏实现流程和模块执行逻辑	以 POMDP、Figure 1/Figure 2、数据源和模块设计为主线
实验描述	分散在 Experiment Settings、Results、Analysis 中	合并为 evaluation protocol、main experiment results 和 four-stage diagnostics
附录	包含环境、rollout、prompt、agent framework 等多个 appendix	当前主 PDF 保留环境配置与 state/action/module/update 细节，减少正文负担
约束文件	无专门约束文件	新增 paper_constraint.md，约束页数、Figure 位置、术语和 product 命名

- 4. 实验结果改为当前 `paper-submit` 数据。新版实验部分基于 `paper_submit_data/outputs/report.md` 和四阶段分析报告，汇总 7 个模型、3 个 frameworks 以及 hand-crafted policy 的最佳结果。Metrics 被重新组织为 viability、sales capability、inventory control、tool use 和 inference cost。
- 5. **Analysis** 改为 **four-stage diagnostics**。新版 Analysis 围绕 evidence acquisition、evidence-to-action conversion、action quality 和 long-horizon adaptation 四个 stage 展开，并配套单栏图表。旧版 analysis 更接近早期 failure case 和行为观察汇总。
- 6. 术语和表格做了收敛。新版统一使用 frameworks，避免 scaffold；全局用 product/products 替代 SKU/SKUs；Table 1 被移入 appendix，并调整 benchmark 引用和列设计。

5 引用审查结果

对当前 latex_arr_revision 的 .tex 文件进行引用抽取后，所有正文 citation key 都能在 custom.bib 中找到，未发现缺失 key。进一步检查 arXiv ID、DOI 和数据集 URL 后，当前版本未发现明确的虚假引用。已做的保守修正包括：

- 修正 McFadden 条目的 booktitle 拼写：Fontiers 改为 Frontiers。
- 为 Amazon Reviews 2023 对应的 hou2024bridging 条目补充 arXiv metadata 和 URL。
- MNL 模型引用中去掉弱相关的书评类引用 Uncles01041987，保留经典 McFadden 引用。
- 移除 revision 目录中未被主文档引用的旧 CAEC/FCR 文件，避免源码包内部出现过期方法叙述。

6 提交建议

建议提交 `paper/latex_arr_revision` 的 LaTeX source、最终 PDF、必要图表、表格、参考文献和本文档 PDF；同时提交 `paper_submit_data` 中用于支撑当前实验结果的分析脚本和输出报告。LaTeX 中间文件、`.DS_Store`、`*.aux`、`*.log`、`*.synctex.gz` 等构建产物不应提交。